

# Predicción de enfermedades neurocognitivas mediante electroencefalografía y Aprendizaje Profundo

Eduardo Montoya, Jose Luis Cadavid y Sofia Muñoz  
Fundamentos de Deep Learning  
Entrega 1

Octubre 2025

## 1. Contexto de aplicación

El presente proyecto se enmarca en la necesidad creciente de desarrollar biomarcadores objetivos, no invasivos y escalables para la detección y diferenciación temprana del Deterioro Cognitivo Leve (MCI), la Enfermedad de Alzheimer (AD) y los estados de riesgo genético. La identificación temprana de estas condiciones es crucial para optimizar la intervención terapéutica y el manejo clínico.

Los métodos diagnósticos actuales, como neuroimágenes o análisis de líquido cefalorraquídeo, suelen ser costosos, invasivos y, en muchos casos, solo confirman el diagnóstico en etapas avanzadas. La electroencefalografía (EEG), en contraste, es una técnica no invasiva, de bajo costo y alta resolución temporal que permite registrar la actividad eléctrica cerebral.

En este proyecto se emplean las potencias espectrales de las señales EEG, segmentadas en las bandas canónicas ( $\delta, \theta, \alpha, \beta, \gamma$ ), registradas en ocho electrodos (FP1, FP2, C3, C4, P7, P8, O1, O2). Estas potencias reflejan la dinámica de redes neuronales, que se alteran significativamente en patologías neurodegenerativas.

## 2. Objetivo de machine learning

El objetivo principal es predecir la condición de salud de cada paciente según su diagnóstico previo: Alzheimer (AD), deterioro cognitivo leve (MCI), control sano (HC) o asintomático con riesgo (ACr). Para ello, las potencias espectrales de las cinco bandas se organizarán en mapas bidimensionales respetando la disposición anatómica de los electrodos: frontales (FP1 y FP2), centrales (C3 y C4), parietales (P7 y P8) y occipitales (O1 y O2).

Cada celda del mapa contendrá un vector con las potencias de las cinco bandas, conformando un tensor de entrada de tamaño  $4 \times 2 \times 5$ . Estos tensores se utilizarán como entrada a redes convolucionales (CNN), con el fin de capturar patrones espaciales y topográficos de la actividad cerebral. Adicionalmente, se incluirán variables categóricas como edad y lugar de registro, para evaluar su influencia en el modelo y su posible contribución o sesgo en la clasificación.

### 3. Dataset

El conjunto de datos empleado contiene registros de pacientes con distintos estados clínicos: Alzheimer (AD), deterioro cognitivo leve (MCI), controles sanos (HC) y asintomáticos con riesgo (ACr). Cada fila del dataset corresponde a un sujeto identificado por las siguientes columnas:

- **Variables demográficas/categóricas:**

- **sub\_group:** subtipo de diagnóstico clínico.
- **subject:** identificador único del paciente.
- **group:** grupo principal (AD, MCI, HC, ACr).
- **age:** edad del paciente.
- **SITE:** centro de registro del EEG.

- **Variables numéricas continuas:** potencias espectrales en bandas canónicas registradas en los electrodos centrales:

- **C3:** 40 columnas de bandas EEG (C3\_Alpha, C3\_Beta, ..., P8\_Theta) → tipo `float64`

El tamaño en disco es  $\sim 638$  KB e incluye 1235 sujetos y 45 columnas que contienen tanto información clínica y demográfica como descriptores espectrales de la actividad cerebral. Estos datos permiten analizar patrones de actividad en las regiones centrales del cerebro, que están asociadas a procesos cognitivos y motores, y cuya alteración ha sido reportada en etapas tempranas de la enfermedad de Alzheimer. La distribución de las clases es de la siguiente manera:

Grupo	Número de sujetos
MCI	408
AD	252
HC_MCI	210
HC_AD	149
ACr	87
HC_ACr	60
SCr	38
HC_SCr	31
<b>Total</b>	<b>1235</b>

Cuadro 1: Distribución de sujetos según la variable `group`.

### 4. Métricas de desempeño

Se emplearán métricas clásicas de clasificación en aprendizaje automático: exactitud (Accuracy), precisión (Precision), Recall y F1-score.

Sea  $TP$  el número de verdaderos positivos,  $TN$  verdaderos negativos,  $FP$  falsos positivos y  $FN$  falsos negativos:

**Accuracy:** Indica el porcentaje de predicciones correctas sobre el total de casos, es decir, qué tan confiable es el modelo en general.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

**Precisión:** Mide la proporción de verdaderos positivos entre todas las predicciones positivas del modelo. Es decir, de todos los que el modelo predijo que están enfermos, cuántos realmente lo están.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2)$$

**Recall:** Evalúa la capacidad del modelo para identificar correctamente los positivos reales. En este caso, indica cuanto de todos los pacientes enfermos, logró detectar el modelo.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

**F1-score:** Representa un balance entre precisión y recall, siendo útil en problemas con clases desbalanceadas.

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

## 5. Referencias y resultados previos

Diversos trabajos han explorado el uso de señales de EEG y métodos de machine learning para la detección y monitoreo de la enfermedad de AD y otras demencias. A continuación se resumen tres estudios representativos:

### Comparación de métricas

Artículo	Dataset	Objetivo	Métricas usadas
Jaramillo-Jiménez et al. (2025)	639 sujetos, EEG en reposo, 11 sitios	Diferenciar múltiples demencias (AD, LBD, FTD, MCI, HC)	AUC, Sensibilidad, Especificidad, VPP, VPN
Jesus et al. (2021)	89 pacientes con AD leve	Predecir puntaje MMSE (severidad cognitiva)	RMSE, $R^2$
Lopes et al. (2023)	54 sujetos (20 HC, 19 AD leve, 15 AD moderado-severo)	Diagnóstico y severidad usando CNNs + espectrogramas de modulación	Accuracy, Precision, Recall, F1-score

Cuadro 2: Resumen comparativo de artículos recientes sobre EEG, machine learning y Alzheimer.